余锋伟

■ forwil@foxmail.com · • (+86) 18810 676 076 · • forwil.xyz · 工作地点:深圳

i TL; DR

行业背景:曾在多个 AI 领军企业的核心部门担任技术管理岗位,对 AI + System 领域具有深刻和独特的见解,具有从 0 到 1 搭建模型训练框架、压缩框架、部署框架、计算调度等深度学习基础设施的成功案例、坚持以业务价值为导向、对算法规模化落地的各类痛点有切身体会和实战经验。

管理能力:具备在高科技上市公司组建和管理 60+人研发团队的经验,曾与多个 985 高校教授建立长期产研合作关系。

学术背景:NOIp 两年一等奖,ASC15 世界一等奖,保送北航计算机本科 + 研究生,综合排名 top5%。于 ICCV / ECCV / CVPR / ICLR / Neurip / ICPP / MLSys / IPDPS /T-PAMI 等 CCF-A/B 会议/期刊上发表 20 多篇论文,Google Scholar 引用量 3500+,H-index 18。

☎ 教育背景

北京航空航天大学, 计算机学院, 软件工程 (双一流 *A*+), 硕士研究生 2015.9 – 2018.3 学位课程平均分: 90.0/100, 排名: 6/241, 北京市优秀毕业生, 国家奖学金。

北京航空航天大学, 计算机学院, 创新实验班(双一流 *A*+), 本科生 2012.9 – 2015.6 核心课程平均分: 88/100, 综合排名: 7/228, 北航优秀毕业生, 获研究生推免资格。

北京航空航天大学, 数学与系统科学学院, 华罗庚实验班, 本科生 2011.8 – 2012.6 NOIp 保送入学, 大二转系进入计算机学院, 加入创新实验班。

👺 工作经历

Momenta 初速度科技, DDInfra(数据驱动基础设施组,团队人数 15+) 研发高级总监 深圳

2023.1-至今

- 整体负责模型训练和推理优化。
- 训练效率优化:提升 D模型在 A100 上的训练效率接近 100%,适配小显存平台 GTX3090;提升 O模型在 3090 上的训练效率达 400%+, D模型在 3090 上训练效率提升 30%,端到端加速 3 倍以上。
- 模型量化:自研模型 PTQ 框架,推动感知模型支持 INT8 PTQ 交付,生产效率从 N 天缩短到 N 小时,机器需求从 100GPU 缩短到 1GPU,精度满足发版需求,同时支持多个 NPU 硬件,包括 orin/高通/瑞萨/mdc/自研芯片。
- 编译推理加速:使用 TVM 优化提升多个核心模型在 orin/xaiver 上的推理效率,提速 10 到 100%。
- Transformer 算子优化: 使用 cutlass/FlashAttention/tvm 等多种手段, 优化 Transformer 在 orin 上的 推理效率、平均提速 30%。

SenseTime 商汤科技, 研究院, 模型工具链 (二级部门负责人, 团队 60+) 2020.9–2022.12 研究副总监 北京/深圳

- 团队工作介绍: https://zhuanlan.zhihu.com/p/268154983, 开源项目组: https://github.com/ModelTC
- 整体负责公司内部研发平台 SenseCore 模型工厂,推动模型生产效率提升,2020: 10000+,2021: 21000+,2022 预计 40000+,年复合增长率 100%。模型工厂包含:
 - **任务调度**: 集群任务调度 SpringScheduler, 覆盖 7000+ 个 GPU, 12+ 个集群;
 - 训练引擎: 研发 linklink 训练引擎, 支持公司 10 亿~ 300 亿参数规模的视觉大模型高效训练;
 - **算法框架**: 研发联合感知模型生产框架 UP, 覆盖检测、属性、3D、分割、跟踪等算法的高效 训练;

- 模型压缩: 负责模型通用压缩技术体系, 包含在线/离线量化, 模型稀疏, 基于硬件真实速度的的网络结构设计平台:
- 模型部署: 负责多平台模型部署评测系统 Adela, 支持 200 多类不同硬件平台自动部署和评测, 其中一半以上为国产化硬件。
- 模型工厂的研发体系覆盖大部分公司业务,包括 90% 以上智慧城市 toG/toB 业务,70% 以上智慧 汽车业务等。
- ICCV-LPCV 2021 低功耗计算机视觉, FPGA 赛道冠军。
- 团队获得 2021 院长创新奖第一名、小荷尖奖, Odrop 获得 2022 年最佳论文奖。
- 同时参与 3 个公司级别的商汤团队奖:通用模型,上市项目,国产化芯片适配。
- 个人获得 2021 年商汤奖提名。
- NART、POD 获得 2021 年度最受欢迎开源项目一等奖、二等奖。

SenseTime 商汤科技, 研究院, 工具链, 链接与编译(部门负责人, 团队 15+) 2016.12–2020.9 研究经理 北京

- 算法部署框架、模型量化工具、深度学习编译器、智能端边 SDK
- 获得研究院 2018 年度杰出员工称号
- SCG/研究院开源技术中台团队获 2019 年商汤团队奖(全公司共两个)
- 前端相机团队获得商汤 2017 年度优秀团队
- 获得商汤 2017 年度未来之星称号。

營 实习/项目经历

基于深度学习的中文文本查错,北京航空航天大学,软件所毕业设计

2016.12-2017.7

• 使用基于 LSTM 的语言模型进行中文文本查错。

SenseTime 商汤科技, 研究中心, 检测跟踪组见习研究员

2016.3-2016.12

- 将动态人脸检测跟踪识别系统从单卡 4 路优化至 16 路,至 TX1 实时处理,再到 CPU 实时处理,最后移植到了嵌入式 IPC (HI3519)中。
- 使用行人检测和 ReID 特征优化了多目标跟踪系统,在 MOT16 榜单上取得包括 MOTA 指标 (68.2 和 66.1)在内的多项第一。
- SenseFace 动态人脸布控系统获 2016 年安防展优秀奖

ASC15 世界大学生超级计算机竞赛

2014.12-2015.5

北航代表队队长

- 在初赛中:负责将 4 台浪潮服务器组成超算小集群的软硬件搭建和维护,对 HPCC 的多个测试子项目(包括 Linpack、FFT、DGEMM)进行深入分析和编译优化,撰写英文 proposal,队伍以初赛大陆第一,世界第二进入全球总决赛。
- 在总决赛中:负责集群软硬件平台搭建、功耗控制、HPL、HPCG调优、WRF-CHEM。应用优化和集群运行策略调度,最终队伍以全球第五名获得一等奖。

Microsoft ARD 微软亚太研发集团,CEC, IoT Group

2014.7-2014.12

- 研发实习生
 - 在智能插座项目中, 为 STM32F 上的.Net Micro Framework 固件添加高级 ADC 操作。
 - 在基于低功耗蓝牙的室内定位项目中,设计并实现在51MCU上的RS-485总线多对一通信协议。

• 在自动化测试项目中, 提取测试程序调用外部库的依赖关系, 存入数据库并对外提供 WCF 接口。

♡ 在校获奖情况

研究生国家奖学金	2017年
华为奖学金	2016年
硕士研究生学业奖学金,一等奖	2015、2016年
ASC15 世界大学生超级计算机竞赛, 一等奖, 第五名	2015年
蓝桥杯全国软件大赛,全国二等奖	2014年
高教社杯全国大学生数学建模竞赛,全国二等奖	2013年
第十一届"福建省小科学家"称号	2011年
全国信息学奥林匹克联赛 (NOIp), 一等奖, 分数: 310/400	2010年
全国信息学奥林匹克联赛 (NOIp), 一等奖, 第七名, 分数: 325/400	2009年

i论文与专利

Exploiting Subgraph Similarities for Efficient Auto-tuning of Tensor Programs.(ICPP2023)

Mingzhen Li, Hailong Yang, Shanjun Zhang, Fengwei Yu, Ruihao Gong, Yi Liu, Zhongzhi Luan, Depei Qian SysNoise: Exploring and Benchmarking Training-Deployment System Inconsistency.(MlSys2023)

Yan Wang, Yuhang Li, Ruihao Gong, Aishan Liu, Yanfei Wang, Jian Hu, Yongqiang Yao, Yunchen Zhang, Tianzi Xiao, **Fengwei Yu**, Xianglong Liu

Exploiting Input Tensor Dynamics in Activation Checkpointing for Efficient Training on GPU.(IPDPS2023)

Jianjin Liao, Mingzhen Li, Hailong Yang, Qingxiao Sun, Biao Sun, Jiwei Hao, Tianyu Feng, **Fengwei Yu**, Shengdong Chen, Ye Tao, Zicheng Zhang, Zhongzhi Luan, Depei Qian

NNLQP: A Multi-Platform Neural Network Latency Query and Prediction System with An Evolving Database.(ICPP2022)

Liang Liu, Mingzhu Shen, Ruihao Gong, Fengwei Yu, Hailong Yang

QDrop: Randomly Dropping Quantization for Extremely Low-bit Post-Training Quantization .(ICLR2022)

Xiuying Wei, Ruihao Gong, Yuhang Li, Xianglong Liu, Fengwei Yu

Supervision Exists Everywhere: A Data Efficient Contrastive Language-Image Pre-training Paradigm.(ICLR2022)

Yangguang Li, Feng Liang, Lichen Zhao, Yufeng Cui, Wanli Ouyang, Jing Shao, Fengwei Yu, Junjie Yan

Real World Robustness from Systematic Noise.(ADMM2021)

Yan Wang, Yuhang Li, Ruihao Gong, Tianzi Xiao, Fengwei Yu

MQBench: Towards Reproducible and Deployable Model Quantization Benchmark.(NeurIPS2021)

Yuhang Li, Mingzhu Shen, Jian Ma, Yan Ren, Mingxin Zhao, Qi Zhang, Ruihao Gong, Fengwei Yu, Junjie Yan Incorporating Convolution Designs into Visual Transformers.(ICCV2021)

Kun Yuan, Shaopeng Guo, Ziwei Liu, Aojun Zhou, Fengwei Yu, Wei Wu

Differentiable Dynamic Wirings for Neural Networks.(ICCV2021)

Kun Yuan, Quanquan Li, Shaopeng Guo, Dapeng Chen, Aojun Zhou, Fengwei Yu, Ziwei Liu

MixMix: All You Need for Data-Free Compression Are Feature and Data Mixing.(ICCV2021)

Yuhang Li, Feng Zhu, Ruihao Gong, Mingzhu Shen, Xin Dong, Shaoqing Lu, Fengwei Yu, Shi Gu

Towards High Performance Extremely Low-bit Neural Networks.(ICCV2021)

Mingzhu Shen, Feng Liang, Ruihao Gong, Yuhang Li, Chuming Li, Chen Lin, **Fengwei Yu**, Junjie Yan, Wanli Ouyang

Diversifying Sample Generation for Accurate Data-Free Quantization.(CVPR2021 oral)

Xiangguo Zhang, Haotong Qin, Yifu Ding, Ruihao Gong, Qinghua Yan, Renshuai Tao, Yuhang Li, **Fengwei** Yu, Xianglong Liu

BRECQ: Pushing the Limit of Post-Training Quantization by Block Reconstruction.(ICLR2021)

Yuhang Li, Ruihao Gong, Xu Tan, Yang Yang, Peng Hu, Qi Zhang, Fengwei Yu, Wei Wang, Shi Gu

Extremely Low-bit Convolution Optimization for Quantized Neural Network on Modern Computer Architectures.(ICPP2020 oral)

Qingchang Han, Yongmin Hu, **Fengwei Yu**, Hailong Yang, Bing Liu, Peng Hu, Ruihao Gong, Yanfei Wang, Rui Wang, Zhongzhi Luan, Depei Qian

DMS: Differentiable Dimension Search for Binary Neural Networks.(ICLR2020 NAS workshop)

Yuhang Li, Ruihao Gong, Fengwei Yu, Xin Dong, Xianglong Liu

Towards Unified INT8 Training for Convolutional Neural Network.(CVPR2020)

Feng Zhu, Ruihao Gong, Fengwei Yu, Xianglong Liu, Yanfei Wang, Zhelong Li, Xiuqi Yang, Junjie Yan Forward and Backward Information Retention for Accurate Binary Neural Networks.(CVPR2020) Haotong Qin, Ruihao Gong, Xianglong Liu, Mingzhu Shen, Ziran Wei, Fengwei Yu, Jingkuan Song Differentiable Soft Quantization: Bridging Full-Precision and Low-Bit Neural Networks.(ICCV2019) Ruihao Gong, Xianglong Liu, Shenghu Jiang, Tianxiang Li, Peng Hu, Jiazhen Lin, Fengwei Yu, Junjie Yan. POI: Multiple Object Tracking with High Performance Detection and Appearance Feature.(ECCV2016 workshop)

Fengwei Yu, Wenbo Li, Quanquan Li, Yu Liu, Xiaohua Shi, Junjie Yan