## 余锋伟

**■** forwil@foxmail.com · **८** (+86) 18810 676 076 · **○** forwil.xyz

### i TL; DR

NOIP 连续两年一等奖,保送北航计算机本硕。ASC15世界一等奖,于ICCV/ECCV/CVPR/Neurip/ICPP等系统/AI会议上发表 20 多篇论文。对 AI + System 领域具有深刻和独特的见解,具有从 0 到 1 搭建模型训练框架、压缩框架、部署框架、计算调度等深度学习基础设施的经验,对算法落地与大规模支持业务有实战经验。具备组建 50+人研发团队的经验,与多个 985 高校教授建立长期产研合作关系。

### ☎ 教育背景

北京航空航天大学, 计算机学院, 软件工程, 硕士研究生

2015.9 - 2018.3

学位课程平均分: 90.0/100, 排名: 6/241, 北京市优秀毕业生, 国家奖学金。

北京航空航天大学, 计算机学院, 计算机学院创新实验班, 本科生

2012.9 - 2015.6

核心课程平均分: 88/100, 本科综合排名 7/228, 北航优秀毕业生, 获得研究生推免资格。

北京航空航天大学, 数学与系统科学学院, 华罗庚数学实验班, 本科生

2011.8 - 2012.6

NOIp 保送入学,大一结束后转系进入计算机学院。

### 🐸 工作经历

**SenseTime 商汤科技**, 研究院, 模型工具链 (二级部门负责人, 团队人数 50+) 2020.9-至今 研究副总监

- 团队工作介绍: https://zhuanlan.zhihu.com/p/268154983
- 团队开源项目: https://github.com/ModelTC
- 工业级 AI 模型生产框架 Spring, 日活 200+, 周活 300+。
- 多平台模型部署评测系统 Adela,上传 onnx 模型,支持 95 类不同硬件平台自动部署和评测。日均新增模型 30+,部署模型 100+。
- 基于 Slurm 的集群任务调度器 SpringScheduler, 覆盖 7000+ 个 GPU, 12+ 个集群, 服务超过 10 个不同团队。
- LPCV 2021 低功耗计算机视觉, FPGA 赛道冠军。

**SenseTime 商汤科技**, 研究院, 工具链, 链接与编译 (部门负责人, 团队 15+) 2019.4–2020.9 研究经理

- 算法部署框架、模型量化工具、训练加速框架、深度学习编译器、智能端边 SDK
- SCG/研究院开源技术中台团队获 2019 年商汤团队奖(全公司共两个)

SenseTime 商汤科技, 研究院, 智能视频, 基础技术与工具组研究员

2018.4-2019.4

- gpu, arm、tx1、movidius 多个架构的前端视频分析算法落地及优化、自研 movidius 深度学习加速库,汇编级优化、自研 arm-quant 定点化加速库, CNN 部署框架 NART,模型量化框架 DRCL。
- 获得研究院 2018 年度杰出员工称号

SenseTime 商汤科技, 研究院, 智能视频, 基础技术与工具组全职见习研究员

2016.12-2018.4

带领小团队、负责智能视频组安防相关所有算法落地和升级、基础工具链搭建。

- 搭建 SenseVideo-GPU-SDK 高性能视频结构化分析系统、推动包括人脸跟踪识别服务器阵列 (TX1)、前端人脸抓拍相机(海思 3519)、前端人脸识别芯片(Movidius 芯片)等前端产品落地。
- 前端相机团队获得商汤 2017 年度优秀团队
- 获得商汤 2017 年度未来之星称号。

### 👺 实习/项目经历

# 基于深度学习的中文文本查错,北京航空航天大学,软件所 毕业设计

2016.12-2017.7

- 背景:传统基于分词和规则错词表的中文查错系统已经被用到实际的中文查错系统中去,但是其依赖于错词表
- 数据: 收集了超过 10 亿字的语料。
  模型和策略: 设计了基于 word-embedding、char level、2-stack-LSTM、dropout 的语言模型,并使用双向模型、拼音相似性等策略来提升识别精度。
- 成果: 系统在 SIGHAN2013 上取得了很好的错误检测精度 (F1: 0.69)。

## SenseTime 商汤科技, 研究中心, 检测跟踪组

2016.3-2016.12

- 见习研究员
  - SenseFace-GPU/CPU-SDK 高性能动态人脸检测跟踪识别系统,维护并优化 GPU 版本 SDK,使其处理速度从单卡 4 路到单卡 16 路。移植到 TX1 嵌入式平台,优化使其支持 2 路高清视频分析。从零编写并维护 CPU 版本,可单核处理一路实时视频流。
  - SenseFace 动态人脸布控系统获 2016 年安防展优秀奖
  - 将人脸检测跟踪算法移植到性能受限的网络监控相机中,并优化至产品可用速度 (12fps)。
  - 使用行人检测和 ReID 特征优化了多目标跟踪系统,在 MOT16 榜单上取得包括 MOTA 指标 (68.2 和 66.1)在内的多项第一。

### ASC15 世界大学生超级计算机竞赛

2014.12-2015.5

北航代表队队长

- 在初赛中: 负责将 4 台浪潮服务器组成超算小集群的软硬件搭建和维护,对 HPCC 的多个测试子项目(包括 Linpack、FFT、DGEMM)进行深入分析和编译优化,撰写英文 proposal,队伍以初赛大陆第一,世界第二进入全球总决赛。
- 在总决赛中:负责集群软硬件平台搭建、功耗控制、HPL、HPCG调优、WRF-CHEM。应用优化和集群运行策略调度,最终队伍以全球第五名获得一等奖。

## Microsoft ARD 微软亚太研发集团,CEC, IoT Group

2014.7-2014.12

- 研发实习生
  - 在智能插座项目中,为 STM32F上的.Net Micro Framework 固件添加高级 ADC 操作。
  - 在基于低功耗蓝牙的室内定位项目中,设计并实现在51MCU上的RS-485总线多对一通信协议。
  - 在自动化测试项目中, 提取测试程序调用外部库的依赖关系, 存入数据库并对外提供 WCF 接口。

### ♡ 获奖情况

研究生国家奖学金	2017 年
华为奖学金	2016年
硕士研究生学业奖学金,一等奖	2015、2016年
ASC15 世界大学生超级计算机竞赛, 一等奖, 第五名	2015 年
蓝桥杯全国软件大赛,全国二等奖	2014 年
高教社杯全国大学生数学建模竞赛,全国二等奖	2013 年
第十一届"福建省小科学家"称号	2011 年

全国信息学奥林匹克联赛 (NOIp), 一等奖, 分数: 310/400 2010 年 全国信息学奥林匹克联赛 (NOIp), 一等奖, 第七名, 分数: 325/400 2009 年

### i论文与专利

#### Real World Robustness from Systematic Noise.(ADMM2021)

Yan Wang, Yuhang Li, Ruihao Gong, Tianzi Xiao, Fengwei Yu

MQBench: Towards Reproducible and Deployable Model Quantization Benchmark.(NeurIPS2021)

Yuhang Li, Mingzhu Shen, Jian Ma, Yan Ren, Mingxin Zhao, Qi Zhang, Ruihao Gong, Fengwei Yu, Junjie Yan Incorporating Convolution Designs into Visual Transformers.(ICCV2021)

Kun Yuan, Shaopeng Guo, Ziwei Liu, Aojun Zhou, Fengwei Yu, Wei Wu

Differentiable Dynamic Wirings for Neural Networks.(ICCV2021)

Kun Yuan, Quanquan Li, Shaopeng Guo, Dapeng Chen, Aojun Zhou, Fengwei Yu, Ziwei Liu

MixMix: All You Need for Data-Free Compression Are Feature and Data Mixing.(ICCV2021)

Yuhang Li, Feng Zhu, Ruihao Gong, Mingzhu Shen, Xin Dong, Shaoqing Lu, Fengwei Yu, Shi Gu

Towards High Performance Extremely Low-bit Neural Networks.(ICCV2021)

Mingzhu Shen, Feng Liang, Ruihao Gong, Yuhang Li, Chuming Li, Chen Lin, **Fengwei Yu**, Junjie Yan, Wanli Ouyang

#### Diversifying Sample Generation for Accurate Data-Free Quantization.(CVPR2021 oral)

Xiangguo Zhang, Haotong Qin, Yifu Ding, Ruihao Gong, Qinghua Yan, Renshuai Tao, Yuhang Li, **Fengwei** Yu, Xianglong Liu

#### BRECQ: Pushing the Limit of Post-Training Quantization by Block Reconstruction.(ICLR2021)

Yuhang Li, Ruihao Gong, Xu Tan, Yang Yang, Peng Hu, Qi Zhang, Fengwei Yu, Wei Wang, Shi Gu

Extremely Low-bit Convolution Optimization for Quantized Neural Network on Modern Computer Architectures.(ICPP2020 oral)

Qingchang Han, Yongmin Hu, **Fengwei Yu**, Hailong Yang, Bing Liu, Peng Hu, Ruihao Gong, Yanfei Wang, Rui Wang, Zhongzhi Luan, Depei Qian

DMS: Differentiable Dimension Search for Binary Neural Networks.(ICLR2020 NAS workshop)

Yuhang Li, Ruihao Gong, Fengwei Yu, Xin Dong, Xianglong Liu

Towards Unified INT8 Training for Convolutional Neural Network.(CVPR2020)

Feng Zhu, Ruihao Gong, Fengwei Yu, Xianglong Liu, Yanfei Wang, Zhelong Li, Xiuqi Yang, Junjie Yan

Forward and Backward Information Retention for Accurate Binary Neural Networks.(CVPR2020)

Haotong Qin, Ruihao Gong, Xianglong Liu, Mingzhu Shen, Ziran Wei, Fengwei Yu, Jingkuan Song

Differentiable Soft Quantization: Bridging Full-Precision and Low-Bit Neural Networks.(ICCV2019)

Ruihao Gong, Xianglong Liu, Shenghu Jiang, Tianxiang Li, Peng Hu, Jiazhen Lin, Fengwei Yu, Junjie Yan.

POI: Multiple Object Tracking with High Performance Detection and Appearance Feature.(ECCV2016 workshop)

Fengwei Yu, Wenbo Li, Quanquan Li, Yu Liu, Xiaohua Shi, Junjie Yan

专利:目标跟踪方法、系统及电子设备(CN201710124025.6) 2017 年 专利:目标对象的检测方法、装置和电子设备(CN201710059806.1) 2017 年 专利:目标对象识别方法、装置、存储介质和电子设备(CN2017111812995) 2017 年

### ▲ 学生工作经历

编译原理/形式语言与自动机,本科课/研究生课,助教

2016.9—2017.1

• 负责批改作业、小测验、实验课习题课讲解

北航高等工程学院高等代数, 助教

2014.9-2015.1

• 负责批改作业、讲授习题课

北航计算机学院创新实验班, 班长

2013.9—2015.7

• 负责通知学生各类事宜,组织班会、聚餐等班级活动

全国信息学奥林匹克联赛 (NOIp),北京赛区,监考员

2013.11

• 监考普及组/提高组,负责解决考生遇到的编译/调试等问题